



Grupo Financiero Ficohsa
Vol 1.0

Gobernanza de Modelos - Área de Riesgos

Ciencia de Datos - Riesgos
Junio 2025





Índice

1. Introducción y Propósito	3
2. Alcance	3
3. Definiciones	3
3.1. ¿Qué es un modelo?	3
3.2. ¿Qué son las métricas de desempeño?	4
4. Principios Rectores	5
5. Roles y Responsabilidades	6
6. Ciclo de Vida del Modelo	6
6.1. Justificación	6
6.2. Desarrollo y Documentación Técnica	6
6.3. Validación Independiente	7
6.4. Aprobación y Registro	7
6.5. Implementación y Monitoreo	7
6.6. Recalibración y Retiro	8
7. Requerimientos Mínimos de Documentación Técnica del Modelo	8
7.1. Ficha Técnica del Modelo	8
7.2. Descripción del Dataset	8
7.3. Fundamentos Metodológico y Justificación	9
7.4. Evaluación de Desempeño	9
7.5. Explicabilidad y Sesgo	9
7.6. Evidencia de Validación Independiente	9
8. Anexo A: Ficha Técnica del Modelo	10
9. Anexo B: Matriz de Roles y Responsabilidades	11
10. Anexo C: Criterios de Validación Técnica	11
11. Ejemplo - Ficha Técnica del Modelo	12





1. Introducción y Propósito

El presente documento establece el **Marco de Gobernanza de Modelos** del Área de Riesgos del Grupo Financiero Ficohsa, con el objetivo de asegurar que todos los modelos utilizados en procesos de toma de decisiones críticas (riesgo, provisiones, rentabilidad, capital económico, cumplimiento regulatorio, colocaciones en diferentes productos, alertas tempranas, cobros, etc) se desarrollen, validen, mantengan y usen de forma responsable, transparente y conforme a estándares internacionales (SR 11-7, IFRS 9, Basilea III) y lineamientos regulatorios de la CNBS.

Asimismo, este marco busca fortalecer la trazabilidad, robustez técnica, transparencia y cumplimiento regulatorio de los modelos utilizados en el Grupo Financiero. Su implementación facilitará una toma de decisiones más precisa, mitigará riesgos operativos, y permitirá alinear los modelos con las mejores prácticas de gobernanza a nivel internacional.

2. Alcance

Este marco aplica a todos los modelos desarrollados o utilizados por las áreas de riesgos (Gestión integral de riesgos de negocio, Riesgos financieros, Riesgo de crédito bancas comerciales, Riesgo de crédito banca consumo, Riesgos no financieros y Riesgos ambiental y social) incluyendo:

- Modelos de scoring y rating.
- Modelos de probabilidad de incumplimiento (PD), Pérdida dado incumplimiento (LGD), Exposición (EAD).
- Modelos de provisiones IFRS 9.
- Modelos de estrés macroeconómico.
- Modelos de apetito de riesgo y optimización del portafolio.
- Modelos Machine Learning / IA.
- Modelos de liquidez.

3. Definiciones

3.1. ¿Qué es un modelo?

Un modelo es un conjunto de métodos, algoritmos, reglas o sistemas que procesan datos para estimar, predecir o clasificar resultados asociados a variables de interés para la toma de decisiones. Incluye desde modelos estadísticos tradicionales, hasta algoritmos de aprendizaje





automático (Machine Learning) o redes neuronales (Deep Learning) aplicados a la gestión de riesgos. Podemos clasificar los modelos como:

- **Modelo Regulatorio:** Modelo utilizado para cumplir con disposiciones normativas o regulatorias, como los relacionados con provisiones bajo IFRS 9 o requerimientos de capital bajo Basilea III.
- **Modelo Interno:** Modelo desarrollado con fines internos de gestión de riesgos o apoyo a decisiones estratégicas, sin requerimientos regulatorios directos.
- **Reentrenamiento:** Proceso mediante el cual se actualiza un modelo con nuevos datos, manteniendo su estructura original, con el fin de preservar su desempeño.
- **Recalibración:** Ajuste de parámetros o coeficientes del modelo sin modificar su estructura o variables.
- **Drift de datos:** Cambio en la distribución de los datos de entrada o en la relación entre variables, que puede afectar el desempeño del modelo.
- **Fairness (Equidad):** Principio que busca garantizar que el modelo no genere sesgos sistemáticos contra grupos protegidos (por ejemplo, por género, edad o etnia).
- **Overfitting:** Fenómeno donde el modelo se ajusta excesivamente a los datos de entrenamiento, perdiendo capacidad de generalización.

3.2. ¿Qué son las métricas de desempeño?

Las métricas de desempeño son indicadores utilizados para evaluar la calidad, precisión y utilidad de un modelo. Las métricas varían según el tipo de modelo, pero comúnmente incluyen:

- **Precisión (Accuracy):** Proporción de predicciones correctas sobre el total de observaciones.
- **Sensibilidad (Recall o True Positive Rate):** Capacidad del modelo para identificar correctamente los casos positivos.
- **Especificidad:** Capacidad del modelo para identificar correctamente los casos negativos.
- **F1 Score:** Media armónica entre precisión y sensibilidad, útil par datasets desbalanceados.





- **AUC-ROC:** Área bajo la curva ROC, mide la capacidad del modelo para discriminar entre clases.
- **RMSE/MAE/MAPE:** Métricas de error comúnmente utilizadas en modelos de regresión.
- **KS:** Mide la máxima diferencia entre las distribuciones acumuladas de eventos y no eventos; comúnmente utilizado en modelos de riesgo de crédito.
- **VaR:** Para modelos financieros, representa la pérdida máxima esperada con un nivel de confianza dado en un horizonte temporal determinado.
- **Expected Shortfall (ES):** Promedio de pérdidas en los casos en que se supera el VaR, relevante para evaluación de cola de pérdida.
- **Backtesting:** Evaluación ex post del rendimiento del modelo, comparando predicciones con resultados reales, especialmente útil en modelos financieros y regulatorios.

La selección de métricas debe estar alineada con el objetivo del modelo, el tipo de datos y el contexto de negocio o regulatorio. No existe una métrica universalmente superior: modelos de clasificación, regresión, riesgos financieros o segmentación requieren evaluaciones distintas. Es fundamental que las métricas sean validadas conjuntamente entre áreas técnicas y las áreas usuarios del modelo, asegurando su relevancia y utilidad en la toma de decisiones. Adicionalmente, se recomienda documentar claramente las métricas seleccionadas en la ficha técnica del modelo y en reporte de validación.

4. Principios Rectores

- Independencia entre desarrollo y validación.
- Trazabilidad y reproducibilidad de cada modelo.
- Documentación técnica y de negocio completa.
- Ciclo de vida controlado desde el desarrollo hasta el retiro.
- Monitoreo continuo del desempeño y ajuste frente a desviaciones.

Auditabilidad y explicabilidad: Todo modelo debe ser trazable, interpretable y reproducible por terceros, incluyendo sus decisiones automatizadas, variables clave y lógica de funcionamiento. Esto es especialmente crítico en modelos complejos como redes neuronales, Machine Learning, Modelos de Lenguaje de Procesamiento Natural.





5. Roles y Responsabilidades

Rol	Funciones Principales
Owner del Modelo	Define el uso y objetivo, interpreta resultados, asegura el alineamiento con el negocio y solicita validación periódica.
Desarrollador	Diseña, entrena, documenta todo lo relacionado con el modelo (supuestos, filtros, análisis de característica, etc)y versiona el modelo. Garantiza calidad técnica y replicabilidad.
Validador Independiente	Revisa técnica, estadística y regulatoriamente (en caso que aplique) el modelo antes de su aprobación.

6. Ciclo de Vida del Modelo

6.1. Justificación

- **Identificación de la necesidad:** Se levanta una necesidad específica desde un área del negocio, riesgos u otra unidad funcional, lo cual considera que un modelo puede apoyar la toma de decisiones estratégicas, operativas o regulatorias. Esta necesidad debe estar claramente vinculada con un problema o meta cuantificable.
- **Documentación del objetivo:** Se debe registrar formalmente el propósito del modelo, incluyendo qué se espera estimar, clasificar o predecir, y cómo esta salida contribuye al objetivo institucional. Se recomienda incluir un resumen ejecutivo que justifique la creación del modelo, así como los criterios que definiran su éxito.

6.2. Desarrollo y Documentación Técnica

- **Lenguajes y entornos aprobados:** El desarrollo del modelo debe realizarse en lenguajes y entornos previamente autorizados por el área de Tecnología y Comité de modelos en caso de existir (por ejemplo, R, Python, SAS, SQL, Microsoft Fabric, Azure, AWS) asegurando su capacidad con los sistemas actuales y su capacidad de ser auditado.
- **Desarrollo técnico:** El equipo o área desarrollador debe construir el modelo a partir de datos validados, aplicando técnicas estadísticamente sólidas o de aprendizaje automático, según corresponda. Se debe mantener registro de las decisiones metodológicas, ajustes, pruebas intermedias y validaciones internas.
- **Documentación estructurada:** Durante el proceso de desarrollo debe generarse documentación técnica que describa con claridad:
 - Las fuentes de datos utilizadas y los criterios de filtrado o exclusión aplicados.





- El tratamiento de datos (limpieza, transformación e imputación).
 - La justificación del algoritmo seleccionado.
 - Los supuestos del modelo y su validación.
 - Las métricas de performance (ej. AUC, KS, RMSE) con los resultados obtenidos en entrenamiento y validación.
 - La evaluación de riesgo de sesgo y consideraciones éticas si aplica.
- **Código fuente organizado:** El código debe estar versionado, contener comentarios explicativos, y ser almacenado en un repositorio institucional (por ejemplo, Git u otro) que garantice su trazabilidad y reutilización.

6.3. Validación Independiente

- **Validación técnica y estadística:** Se realiza una validación independiente por parte de un equipo distinto al desarrollador. Esta validación busca asegurar que el modelo cumple los estándares de robustez, precisión y alineamiento con su proposito original.
- **Emisión de recomendaciones:** El resultado de la validación se documenta en un reporte formal que incluye hallazgos, riesgos identificados y recomendaciones específicas para su ajuste o mejora si aplica. Este informe debe acompañar cualquier solicitud de aprobación ante el comite de modelos.

6.4. Aprobación y Registro

- **Evaluación por Comite:** El comite de modelos analiza el modelo propuesto con base en la documentación técnica, el informe de validación independiente y los criterios establecidos en este marco de gobernanza. Solo los modelos que cuenten con el visto bueno del comite pueden avanzar a etapas de implementación.
- **Registro formal:** Los modelos aprobados deben ser registrados en la **Base Maestra de Modelos de Riesgos (BMMR)**, un repositorio centralizado de modelos alojado en entornos tecnológicos institucionales (por ejemplo, Data Lake, Microsoft Fabric u otra plataforma autorizada). Este registro permitirá trazabilidad, control y cumplimiento regulatorio.

6.5. Implementación y Monitoreo

- **Puesta en producción:** El modelo aprobado se implementa en el entorno productivo bajo control de versiones, asegurando que los cambios estén debidamente auditados y documentados. Se debe garantizar que la lógica del modelo en producción coincida con lo aprobado técnicamente.





- **Monitoreo continuo:** Se establecen indicadores de desempeño (como las vistas en la sección 3.2) para detectar desviaciones que pueden comprometer la integridad del modelo.

6.6. Recalibración y Retiro

- **Revisión periódica:** Se establecen ventanas de revisión anuales o cuando se detecten un deterioro significativo en el desempeño del modelo. El análisis debe determinar si es necesario recalibrar, rediseñar o reemplazar el modelo.
- **Cierre documentado:** Si se determina que un modelo ha perdido utilidad o validez, se procede con su cierre formal. Este debe ser documentado detalladamente, indicando causas, fecha efectiva, y si aplica, el modelo que lo reemplaza. Esta información debe actualizarse en la **Base Maestra de Modelos de Riesgos**.

7. Requerimientos Mínimos de Documentación Técnica del Modelo

Todo modelo desarrollado dentro del Grupo Financiero deberá contar con una documentación mínima estandarizada, la cual es responsabilidad del área o persona que lidera su construcción. Esta documentación es indispensable para asegurar la transparencia, validación, trazabilidad y preparación para su posterior puesta en producción.

Los elementos mínimos que debe contener dicha documentación son los siguientes:

7.1. Ficha Técnica del Modelo

En los anexos de esta documentación debe estar una ficha técnica como la que se visualiza en el Anexo A.

7.2. Descripción del Dataset

Debe incluir:

- Fuentes de origen de datos
- Periodo de análisis y corte
- Criterio de exclusión/inclusión de datos
- Tratamientos aplicados (limpieza, codificación, imputación)
- Diccionario de variables empleadas





7.3. Fundamentos Metodológico y Justificación

- Descripción de la lógica del modelo y su racionalidad estadística o computacional
- Motivo de la selección del algoritmo
- Alternativas exploradas (si aplica)
- Evaluación de supuestos y consistencia del modelo la teoría del riesgos

7.4. Evaluación de Desempeño

- Resultados de entrenamiento y validación
- Métricas utilizadas y justificación de su elección (ej. ver sección 3.2)
- Análisis de sensibilidad o estabilidad
- Evidencia de no sobreajuste

7.5. Explicabilidad y Sesgo

Para modelos complejos, como aquellos basados en algoritmos de machine learning o deep learning, el desarrollador deberá incluir una evaluación de explicabilidad utilizando herramientas como SHAP, LIME u otras técnicas equivalentes. Asimismo, deberá documentarse cualquier análisis de sesgo potencial hacia grupos vulnerables y, si aplica, las acciones tomadas para mitigar dichos riesgos.

7.6. Evidencia de Validación Independiente

- Reporte de validación o validadores externos al área que desarrollo el modelo.

Toda esta información expuesta en esta sección será solicitada por los validadores independientes y constituye un prerequisite obligatorio para avanzar hacia las fases de validación y puesta en producción.





8. Anexo A: Ficha Técnica del Modelo

Campo	Descripción
Nombre del Modelo	Nombre descriptivo del modelo
Código Interno	ID único en la Base Maestra de Modelos de Riesgos
Área Propietaria	Área responsable (ej. Riesgo Consumo)
Propósito del Modelo	Descripción del objetivo
Tipo de Modelo	predictivo / Diagnóstico / Prescriptivo
Algoritmo o Técnica	Ej. XGBoost, ARIMA, LSTM, etc
Variables predictoras	Lista de variables explicativas
Variable Objetivo	Ej. PD, M90, Score
Lenguaje y Entorno	R / Python / SAS / Azure Databricks
Versión del Modelo	1.0, 1.1, ... según actualizaciones
Fecha de Desarrollo	Mes/Año
Fecha de Validación	Mes/Año
Fecha de Producción	Mes/Año
Validador	Nombre del área o persona
Desarrollador(es)	Nombre(s) del equipo o persona que desarrollo el modelo
Métricas de evaluación	AUC, MAPE, Accuracy, KS, etc
Dataset de Entrenamiento	Origen, periodo y fuente
Segmento de Aplicación	Ej. Tarjetas, Préstamos, Hipotecas, cobros, etc.
Frecuencia de Reentrenamiento	Trimestral / Anual / Condicional
Estado Actual	En desarrollo / En uso / Revisión / Retirado
Ubicación del Código Fuente	URL en Git Institucional
Documentación Complementaria	PDF, README, notebooks, etc.



9. Anexo B: Matriz de Roles y Responsabilidades

Rol	Responsable	Funciones
Owner del Modelo	Gerencia de Riesgos (Créditos, Consumo, etc.)	Definir, interpretar resultados, monitorear uso
Desarrollo	Data Science u otro	Desarrollo técnico, entrenamiento, documentación
Validación independiente	Unidad de validación de modelos	Evaluar técnica, estadística y regulación
Comite de Modelos	Representante de riesgos, finanzas	Aprobar modelos nuevos o cambios
Ecosistema u otro	Data Engineering/TI	Despliegue, infraestructura, soporte

10. Anexo C: Criterios de Validación Técnica

Categoría	Criterio	Método de Evaluación
Calidad del Modelo	Justificación técnica y estadística clara	Revisión documental y cálculo de métricas
Performance Predictivo	$AUC > 0,70$, $KS > 25\%$ o criterio definido por el Owner	Validación cruzada, test out-of-sample
Riesgos del Modelo	Evaluación de Overfitting, drift y bias	Análisis de SHAP, estabilidad por segmento
Robustez del Dataset	Fuente de datos, imputación, equilibrio	Exploración de calidad de datos, proporciones
Documentación	Clara, reproducible y versionada	Validación contra checklist de documentación
Cumplimiento Regulatorio	Alineado a CNBS, IFRS 9, Basilea	Checklist legal / regulatorio
Explicabilidad y Ética	SHAP/LIME/ICE para modelos no lineales	Revisión del informe de interpretabilidad

11. Ejemplo - Ficha Técnica del Modelo

Campo	Contenido
Nombre del Modelo	Modelo de Probabilidad de Incumplimiento (PD) Tarjetas - XG-Boost
Código Interno	00001
Área Propietaria	Riesgo de Crédito Consumo
Propósito	Estimar la probabilidad de que un cliente caiga en M90+ en los próximos 12 meses
Tipo de Modelo	Predictivo
Algoritmo o Técnica	XGBoost con grid search y validación cruzada
Variables predictoras	Tasa Política Monetaria, Reservas Netas, Score Interno, Antigüedad del Cliente, % de Utilización
Variable Objetivo	M90 (1 si >90 días vencido, 0 si no)
Lenguaje y Entorno	Python 3.10 (Sklern xgboost)
Versión del Modelo	1.0
Fecha de Desarrollo	Mayo 2025
Validador	Área de Ciencia de Datos
Desarrollador(es)	Equipo Analítica Riesgo Consumo
Métricas de Evaluación	AUC: 0.823, KS: 0.46, MAPE: 8.2 %
Dataset de Entrenamiento	Clientes activos (2020-2024), variables macroeconomicas mensuales
Segmento de Aplicación	Tarjetas de crédito V+
Uso en procesos Clave	Asignación de líneas, provisiones IFRS9
Frecuencia de Reentrenamiento	Anual o si hay deterioro en el performance
Estado Actual	En producción
Ubicación del Código Fuente y Dataset del modelo	GitLab Ficohsa: / riesgos /pd_modelos/XGBoost 2025
Documentación Comple-mentaria	README técnico, manual usuario, validación.pdf



12. Referencias Bibliográficas y Técnicas

- Board of Governors of the Federal Reserve System. (2011). *SR 11-7: Guidance on Model Risk Management*. Disponible en: <https://www.federalreserve.gov>
- Bank for International Settlements (BIS). (2006–2019). *Basel II y III Frameworks: International Convergence of Capital Measurement and Capital Standards*. BIS Publications.
- Hand, D. J., & Till, R. J. (2001). *A Simple Generalisation of the Area Under the ROC Curve for Multiple Class Classification Problems*. *Machine Learning*, 45(2), 171–186.
- Hyndman, R. J., & Athanasopoulos, G. (2018). *Forecasting: Principles and Practice* (2nd ed.). OTexts. Disponible en: <https://otexts.com/fpp2/>
- SAS Institute Inc. (2016). *Credit Scoring for Risk Managers: The Handbook for Lenders*. Cary, NC.
- Moody's Analytics. (2018). *Best Practices in Credit Scorecard Development and Validation*. Research Brief.
- European Central Bank. (2017). *Guidance on the use of models in the Internal Ratings-Based Approach*. ECB Banking Supervision.
- Office of the Comptroller of the Currency (OCC). (2021). *Model Risk Management: OCC Bulletin 2021-41*.
- Scikit-learn Developers. (2023). *Model Evaluation Metrics*. Documentación oficial. Disponible en: <https://scikit-learn.org>

